

梁展宏

17620043415

cw252128385@163.com

<https://github.com/ZhanhongLiang>

实习

AI Agent应用开发 (Java后端方向)



教育经历

广东工业大学 人工智能 硕士 | 排名前10% | 通过CET-6

2024-09 ~ 2027-06

CCF-C PRCV会议 一作Oral | 国家授权发明专利 | RoboCup中国无人机挑战赛国三 | 校奖学金一等奖

哈尔滨理工大学 机械设计及其自动化 本科

2017-09 ~ 2021-06

东北三省数学建模省赛一等奖 | 大疆Robomaster北部赛区三等奖

项目经历

设备运维智能问答与故障诊断 Agent 平台 | Java后端 + AI应用开发

2026-01 ~ 2026-04

<https://www.argusagent.online>

技术栈: SpringBoot + MyBatis Plus + PgVector + Redis + Redisson + Tika + Sa-Token + RAGAS + MCP

业务痛点: 工厂设备手册、故障案例资料分散, 人工排查故障耗时久, 专业设备术语导致口语化提问检索精度差; 台账、备件、工单数据分散无统一 MCP 调用入口, 咨询高峰并发高易超时, 多轮故障对话上下文膨胀推高大模型调用成本; 且设备文档按车间涉密, 缺乏细粒度权限隔离机制。

业务目标: 搭建制造业运维 RAG 智能问答平台, 依托 MCP 打通运维数据工具, 落地多路检索、会话压缩、并发限流与分级权限能力, 配套 RAGAS 自动化评测体系, 提升故障检索精度, 减少运维人力与 LLM 算力开销。

- 意图识别与MCP工具路由: 搭建分层意图识别树, 区分设备资料检索、故障诊断、备件库存查询、维修工单调取四类意图; 低置信模糊故障问句自动发起澄清反问, 通过 LLM 提取设备编号、产线、故障现象等参数, 统一接入 MCP 网关调用模拟运维业务工具; 基于 Sa-Token 实现车间 + 班组两级权限隔离, 跨产线涉密设备文档直接拦截。
- 检索增强: 意图定向设备故障案例精准检索 + 全局设备手册向量召回双链路并行, 基于 PgVector 构建设备文档向量索引, 完成结果去重、Reranker 精排、动态 TopK 截断过滤无关故障案例; 对比传统单向量 RAG, Top1 故障案例召回命中率提升 28.5%。
- LLM 问题重写&并行拆分: 针对口语化故障描述、多故障复合问句做专业术语归一化、指代消解、子任务拆分, 并行执行多路子查询, Recall@1 指标提升 18.8%。
- 双层会话记忆管控: 限制单轮对话 Token 预算, 自动裁剪历史故障沟通记录并生成轻量化摘要缓存, 降低长对话推理开销; 基于 Redis 信号量、ZSet、Lua 原子脚本实现请求公平排队、超时拒绝, 结合 SSE 推送队列实时状态, 保障高峰期流式问答稳定。
- RAGAS 全链路评测: 搭建覆盖故障检索 HitRate、MRR、故障回答相关性、设备信息幻觉率、接口延迟 20+ 指标的自动化评测体系, 支持 A/B 版本对比、单故障样本归因分析与人工校正, 持续迭代检索策略与知识库, 最终设备问答答案忠诚度提升 10.3%、内容相关性提升 8.0%。

项目量化成果: 产线故障自主排查效率提升 85%, 同时通过双层会话压缩将长对话 Token 消耗降低 36%, 显著减少维修工程师重复资料查阅工作量与大模型调用成本。

Mindpilot · 心理场景事件驱动多 Agent平台 | Python后端+Agent应用开发

2026-03 ~ 2026-07

<https://www.roseagent.online>

技术栈: Python、FastAPI、Harness Engineering、Skill、Redis、Chroma、MCP、Docker、MySQL、RAG、SQLAlchemy、Basic Auth

业务痛点: 心理咨询场景存在风险识别、分级预警、个案报告生成多环节割裂; Agent 调用、数据持久化、工具后处理耦合严重, 迭代维护成本高; 多智能体无统一协作调度, 任务冲突、重复执行; 缺少标准化测试环境, RAG、路由、安全流程回归验证成本高; 高风险预警、Excel 导出等后置工具阻塞流式对话, 无失败重试、死信兜底机制。

业务目标: 自研 Runtime Harness 与黑板协作机制统一智能体生命周期; 以分层记忆、心理 RAG、自动化工程验证和异步 MCP 工具队列, 构建风险识别、分级预警、人工跟进的安全闭环。

- Agent Runtime 与多 Agent 协作: 设计并实现 MindPilotAgentHarness, 统一处理输入脱敏、会话管理、Agent 调用、消息/报告/Run Trace 落库和工具计划; 基于 CollaborationBlackboard 实现事件驱动协作, Coordinator 按能力 Claim 动态调度任务, SafetyAgent 审核候选回复后由 Coordinator 最终采纳。
- RAG、记忆与 Skill: 实现 Redis 短期记忆 + MySQL 回填、窗口裁剪与摘要压缩, 生成 memoryBrief、受限 modelHistory; 实现 Chroma + BM25 混合检索、分数融合、本地重排与邻块扩展, 并通过 MindPilotSkillRegistry 动态加载 SKILL.md, 高风险强制注入安全计划和个案交接摘要。
- 工程验证与异步工具: 建设 SQLite + 内存短期记忆替身的一键 Engineering Harness, 覆盖 Risk Safety、Agent Routing、Standard Skills、RAG、API、Tool Queue 六类链路; 封装 Excel、预警、备注等 MCP 工具并实现异步队列, 支持幂等、依赖控制、限流、失败重试与 Dead Letter, 避免阻塞 SSE 流式回复。

项目量化成果: 项目实现 Agent 业务迭代效率提升 60%, 多智能体协同使人工介入工作量减少 75%, 分层记忆压缩将超长会话 Token 占用降低 45%, 显著提升系统维护效率与推理性能。

专业技能

- Java / Python 后端开发: 熟悉 Java、Spring Boot、MyBatis-Plus、Sa-Token, 以及 Python、FastAPI、SQLAlchemy、Pydantic; 具备 RESTful API、SSE 流式服务、权限控制、模块化架构与 Docker 部署经验。
- Agent 与 RAG 工程: 掌握 ReAct、MCP、Skill、Harness Engineering、多 Agent 协作与上下文压缩, 熟悉 LangChain、LangGraph、Deep Agents; 具备 PgVector、Chroma、BM25、Reranker、动态 TopK 及 RAGAS 自动化评测实践。
- 数据与工程提效: 熟悉 MySQL、PostgreSQL、Redis、Redisson、Lua、限流、幂等、重试和死信队列; 了解 SFT、LoRA、DPO、模型蒸馏与 Reasoning 数据构造, 熟练使用 Claude Code、Codex、Cursor、Trae, 开发效率提升 5 倍以上。

